

El draft de fantasy football como problema de optimización con restricciones

Optimización de Markowitz (media y varianza) con dos estrategias,
resuelta mediante Punto Interior y Descenso de Gradiente Proyectado

Manuel McCadden

Proyecto Final

Optimización Numérica

Instituto Tecnológico Autónomo de México (ITAM)

Octavo semestre | Mayo de 2026

Índice

1. Introducción y motivación	2
2. Modelo: datos, parámetros y estrategias	3
2.1. Datos	3
2.2. Puntos esperados μ	3
2.3. Riesgo Σ	4
2.4. Las dos estrategias	4
3. Método de optimización	5
3.1. Formulación del problema	5
3.2. Reemplazo dinámico y factibilidad de ADP	5
3.3. Estrategia 1: programa cuadrático convexo	5
3.4. Estrategia 2: minimización de una función cóncava	6
3.5. De la relajación a una selección discreta	7
4. Simulaciones y resultados	7

Resumen

Planteamos el *draft* de *fantasy football* (la selección secuencial de jugadores en formato “serpiente”) como una sucesión de programas cuadráticos con restricciones. En cada turno propio se maximiza una utilidad de tipo Markowitz sobre los jugadores disponibles, combinando los puntos esperados, el valor respecto al nivel de reemplazo de su posición, las preferencias del participante y un término cuadrático de riesgo construido con la covarianza, sujeta a una restricción de factibilidad de ADP que limita la plantilla a la que es realmente reclutable desde la posición de selección. Se estudian dos actitudes opuestas ante el riesgo: una estrategia de *piso* (minimizar la varianza), que es un programa cuadrático convexo resuelto de forma exacta por el método de **Punto Interior**, y una estrategia de *techo* (maximizar la varianza), que es un problema no convexo resuelto por **Descenso de Gradiente Projectado** cuya etapa de proyección es, a su vez, un programa cuadrático convexo. El modelo se calibra con datos reales semanales de *nflverse* (de 2021 a 2024), con una covarianza sensible a la disponibilidad y proyecciones ancladas al mercado (ADP). Las simulaciones de Monte Carlo muestran que cada estrategia domina en la métrica que optimiza y que ambas presentan una separación nítida entre riesgo y rendimiento.

1. Introducción y motivación

El *fantasy football* es un juego de gestión deportiva. Cada participante dirige un equipo imaginario integrado por jugadores reales de la NFL. Cada semana, el desempeño estadístico real de esos jugadores (yardas, anotaciones, recepciones, etc.) se convierte en puntos mediante un sistema de puntuación (aquí PPR: un punto por recepción), y, dentro de una liga, gana el enfrentamiento semanal el equipo cuya alineación acumula más puntos. Antes de que comience la temporada, todos los participantes de la liga participan en un *draft*: por turnos eligen jugadores, y cada jugador puede pertenecer a un solo equipo. El orden de elección es de tipo serpiente (*snake*): se invierte ronda con ronda, de modo que quien elige primero en una ronda elige último en la siguiente.

Visto así, el draft es un problema de **asignación secuencial de recursos bajo incertidumbre**: en cada turno hay que escoger un jugador de un conjunto que se va agotando, anticipando tanto las elecciones de los rivales como las posiciones que todavía faltan por cubrir para armar una alineación válida.

Este problema admite una lectura natural en términos de **teoría de portafolios**. Los jugadores son los activos; su proyección de temporada es el rendimiento esperado μ ; la covarianza semanal de los puntos es la matriz de riesgo Σ . Un equipo es un portafolio (con pesos 0/1) sujeto a restricciones de cupo y de posición. Tres factores hacen interesante el problema y justifican un enfoque de optimización:

- **Escasez posicional**: los *running backs* y *wide receivers* de élite son escasos y los *quarterbacks* y *tight ends* abundan, así que lo que importa es el valor respecto al nivel de reemplazo, no los puntos brutos.
- **Correlación**: un *quarterback* y su receptor están correlacionados positivamente, lo que para una estrategia es riesgo y para la otra potencial de techo.
- **Riesgo de disponibilidad**: una estrella lesionada aporta cero esas semanas, lo que domina el riesgo real y debe entrar en Σ .

2. Modelo: datos, parámetros y estrategias

2.1. Datos

El modelo se alimenta de tres fuentes públicas. La temporada 2025 no interviene en ninguna estimación: se reserva para evaluar las estrategias.

Estadísticas semanales (nflverse). Del repositorio `nflverse-data` (*release player_stats*) se descargaron los archivos `player_stats_2021.csv` a `player_stats_2024.csv`. De cada registro jugador-semana se usaron los campos `player_display_name`, `position`, `recent_team`, `season`, `week`, `season_type` y, sobre todo, `fantasy_points_ppr`: los puntos de fantasía en formato PPR (un punto por recepción) ya calculados por `nflverse` a partir de las estadísticas de cada partido. Se conservaron solo la temporada regular (`season_type = REG`) y las posiciones ofensivas QB, RB, WR y TE. Esto deja del orden de 21,000 observaciones jugador-semana sobre unos 980 jugadores y cuatro temporadas, con las que se estiman μ^{hist} y Σ .

Estadísticas de pateadores (nflverse). El feed de ofensiva no incluye *kickers*; sus puntos semanales se toman del conjunto de pateo de `nflverse` (de 2021 a 2024) con la puntuación estándar (3, 4 o 5 puntos por gol de campo según distancia y 1 por punto extra). Quedan unos 27 pateadores con historial real, estimados igual que el resto.

ADP de pretemporada 2025. El orden de mercado proviene de *drafts* simulados de pretemporada 2025, en formato PPR de 12 equipos: la base principal es FantasyFootballCalculator y la cola del ranking se completa con el consenso de FantasyPros. Son alrededor de 191 jugadores con su posición, equipo y ADP. El ADP entra en μ (Sección 2.2) y, además, fija el orden con el que los rivales seleccionan en la simulación.

Novatos 2025 y riesgo de lesión. La clase de novatos del *draft* de la NFL de 2025 (jugadores ofensivos de *skill*, unos 43) se incorpora con su equipo y un nivel de riesgo de lesión en $[0, 1]$. Para los veteranos ese nivel resume su historial de lesiones; para los novatos, las señales disponibles antes de su primera temporada. El riesgo escala la varianza individual en Σ (Sección 2.3).

2.2. Puntos esperados μ

Para cada jugador i combinamos su desempeño histórico con la información del mercado mediante una combinación convexa:

$$\mu_i = \beta \mu_i^{\text{hist}} + (1 - \beta) \mu_i^{\text{ADP}}, \quad \beta = 0,30.$$

μ_i^{hist} es la media de los puntos PPR semanales reales del jugador en los partidos que disputó, ponderada para dar más peso a las temporadas recientes (un factor 0,55 por cada temporada de antigüedad) y escalada a una temporada de 17 partidos. μ_i^{ADP} es la proyección implícita en la posición media de selección del mercado; recibe el 70 % del peso porque incorpora información prospectiva que las estadísticas pasadas no capturan (cambios de equipo, esquema ofensivo, pretemporada).

A partir de μ_i se construye el término lineal a_i del problema de selección. Si la plantilla ya tiene k_p jugadores en la posición $p = \text{pos}(i)$ y esa posición admite κ_p titulares, el rendimiento se descuenta por redundancia con un factor geométrico y se resta el nivel de reemplazo r_p de la posición:

$$a_i = \delta^{\max(0, k_p - \kappa_p + 1)} \mu_i - r_p + b_i, \quad \delta = 0,30,$$

donde b_i es la preferencia opcional del participante (por un jugador o por una posición). El factor $\delta^{(\cdot)}$ penaliza acumular suplentes en una posición ya cubierta; la resta de r_p es el valor sobre el reemplazo, que hace escasa a una posición con caída brusca de talento. El nivel r_p es *dinámico*:

el mejor jugador de la posición que se espera siga disponible en nuestra siguiente selección (el reemplazo si esperamos), y se define en la Sección 3.2. La factibilidad de ADP, una restricción aparte de la misma sección, limita además qué plantillas son realmente reclutables.

2.3. Riesgo Σ

Σ mide cómo covarían, semana a semana, los puntos de los jugadores. Un detalle es decisivo: se construye sobre las 17 semanas de cada temporada en que el jugador estuvo en activo, **asignando cero a los partidos que no disputó**. Así, perderse media temporada por lesión castiga el riesgo del jugador; una covarianza basada solo en los partidos jugados ocultaría ese riesgo.

El estimador $\hat{\Sigma}$ es la covarianza muestral de los puntos semanales, escalada por 17 para expresarla por temporada: si las semanas fueran independientes, la varianza de un total de 17 partidos es 17 veces la semanal, la misma escala que μ . Se calcula por pares, es decir, cada entrada usa solo las semanas en que ambos jugadores coinciden (y las parejas con muy poco solapamiento se anulan). Esto tiene una consecuencia: con datos completos, una covarianza muestral es un producto $\frac{1}{n}X_c^\top X_c$ y es semidefinida positiva por construcción; aquí no, porque cada entrada proviene de un subconjunto distinto de semanas. Cada covarianza es válida por separado, pero el conjunto no corresponde a una única distribución conjunta y la matriz resulta fuertemente *indefinida* (cientos de eigenvalores negativos). Se corrige con una contracción hacia la diagonal seguida de una proyección al cono semidefinido positivo:

$$\Sigma = P_{\succeq 0}[(1 - \alpha)\hat{\Sigma} + \alpha \text{diag}(\hat{\Sigma})], \quad \alpha = 0,10.$$

La contracción es suave y conserva el 90 % de las correlaciones, que son el componente dominante del riesgo (los términos fuera de la diagonal explican cerca del 40 % del riesgo de un equipo). La proyección $P_{\succeq 0}$ recorta a cero los eigenvalores negativos y entrega la matriz de covarianza válida más cercana en norma de Frobenius; no borra covarianzas negativas, sino *direcciones* de varianza negativa. Aunque modifica $\hat{\Sigma}$ cerca de un 19 %, es indispensable: solo con $\Sigma \succeq 0$ el riesgo $w^\top \Sigma w$ es una varianza no negativa y el Hessiano $2\lambda \Sigma$ de la Estrategia 1 es semidefinido positivo, lo que la vuelve genuinamente convexa y deja que el Punto Interior alcance el óptimo global.

Los jugadores sin historial en la NFL (novatos y defensas) reciben una σ a priori por posición; a los novatos, además, se les reduce μ un 10 % y se les triplica la varianza, para reflejar su mayor incertidumbre. De este modo el talento (μ) y el riesgo (σ) quedan *desacoplados*: cada jugador cae automáticamente en un cuadrante de riesgo y rendimiento, por ejemplo un corredor “arriesgado pero excelente” frente a un receptor “seguro”.

2.4. Las dos estrategias

Con el término lineal a y el peso de riesgo $\lambda = 0,015$, el modelo plantea dos objetivos opuestos sobre la misma región factible:

$$\text{Estrategia 1 (piso): } \max_w a^\top w - \lambda w^\top \Sigma w, \quad \text{Estrategia 2 (techo): } \max_w a^\top w + \lambda w^\top \Sigma w.$$

El cambio de signo convierte en recompensa la correlación entre compañeros de equipo (penalizada en la Estrategia 1), de modo que la Estrategia 2 favorece los *stacks* y los jugadores de alta varianza. Los parámetros del modelo son $\lambda = 0,015$, $\beta = 0,30$ (peso histórico frente al ADP), factor de recencia 0,55, descuento por redundancia $\delta = 0,30$, contracción $\alpha = 0,10$, multiplicador de varianza de novatos 3,0 y reducción de μ de novatos del 10 %.

3. Método de optimización

3.1. Formulación del problema

En cada turno propio, sea $w \in \mathbb{R}^n$ el vector de decisión sobre los n jugadores candidatos. El término lineal $a \in \mathbb{R}^n$ recoge el valor de cada jugador (su μ ponderado por profundidad, menos el nivel de reemplazo de su posición, más las preferencias del participante); $\Sigma \in \mathbb{R}^{n \times n}$ es la covarianza, simétrica y semidefinida positiva, y $\lambda > 0$. El problema que se resuelve es

$$\begin{aligned} \min_{w \in \mathbb{R}^n} \quad & U_s(w) = -a^\top w + s \lambda w^\top \Sigma w \\ \text{sujeto a} \quad & \mathbf{1}^\top w = p_k, \\ & \ell_p \leq \sum_{i \in P_p} w_i \leq u_p, \quad p \in \{\text{QB, RB, WR, TE, K, DST}\}, \\ & \sum_{i: \text{adp}_i < P_m} w_i \leq m, \quad m = 1, \dots, p_k, \\ & 0 \leq w_i \leq 1, \quad i = 1, \dots, n, \end{aligned} \tag{1}$$

con $s = +1$ para la Estrategia 1 (piso) y $s = -1$ para la Estrategia 2 (techo). Aquí p_k es el número de selecciones que aún nos quedan; P_p es el conjunto de candidatos de la posición p ; y ℓ_p, u_p son los cupos mínimo y máximo de esa posición, ajustados a la plantilla ya formada (cuando $\ell_p = u_p$, como en *kicker* y defensa, esa fila es una igualdad). Los cupos mínimos garantizan que el equipo pueda alinear una titularidad válida. La tercera familia de restricciones es la factibilidad de ADP: $P_1 < \dots < P_{p_k}$ son los números de selección globales de nuestros turnos restantes en el orden serpiente, y se explica en la Sección 3.2. Los jugadores ya tomados o vetados se excluyen del conjunto de candidatos (equivalen a $w_i = 0$), y la optimización se restringe a una lista corta: los candidatos de mayor a_i y, por cada posición, las opciones realistas más profundas, de modo que siempre exista una plantilla factible. Llamamos Ω a la región factible de (1): la intersección de un hiperplano, las restricciones lineales por posición, la escalera de factibilidad de ADP y la caja $[0, 1]^n$, es decir, un conjunto convexo y compacto. Maximizar $a^\top w \mp \lambda w^\top \Sigma w$ equivale a (1).

3.2. Reemplazo dinámico y factibilidad de ADP

Dos mecanismos distintos capturan el reloj del *draft*. El **reemplazo dinámico** fija el *valor*: r_p (Sección 2.2) es el mejor jugador de la posición p que se espera siga disponible en nuestra siguiente selección, ya que los rivales eligen por ADP y entre dos turnos nuestros desaparecen los de menor ADP de esa ventana serpiente. Restarlo mide el valor respecto al siguiente disponible: una posición que se vacía rápido (*running backs* de élite) tiene un reemplazo futuro mucho peor, así que urge elegir ya; una profunda (*kicker*, defensa) sigue casi intacta al siguiente turno, $r_p \approx \mu_i$ y su valor ≈ 0 , así que se pospone sola, sin reglas codificadas a mano. La **factibilidad de ADP** fija el *conjunto factible*: la relajación repartiría p_k cupos como si pudiéramos reclutar de golpe toda la plantilla, y la escalera $\sum_{\text{adp}_i < P_m} w_i \leq m$ lo impide (un jugador con $\text{adp}_i < P_m$ se da por tomado para nuestra m -ésima selección salvo que lo aseguremos antes). Es una restricción sobre Ω , no sobre el valor: los dos papeles no se confunden.

3.3. Estrategia 1: programa cuadrático convexo

Como $\Sigma \succeq 0$ y $\lambda > 0$, el Hessiano de la Estrategia 1 ($s = +1$) es

$$\nabla^2 U_1(w) = 2\lambda \Sigma \succeq 0,$$

de modo que U_1 es convexo y, sobre el conjunto convexo Ω , (1) es un **programa cuadrático convexo**: todo mínimo local es global y las condiciones KKT son necesarias y suficientes. Lo resolvemos con el **método de Punto Interior** derivado de KKT. La única igualdad (el presupuesto $\mathbf{1}^\top w = p_k$) se elimina sustituyendo una variable, de modo que el problema queda solo con desigualdades $g_j(w) \leq 0$ (los cupos por posición y la caja $0 \leq w_i \leq 1$). El punto inicial w_0 debe vivir en el *interior* de Ω , es decir $g_j(w_0) < 0$ para toda j ; se obtiene con una fase I que maximiza el margen mínimo a las desigualdades.

Partiendo de KKT, se relaja la condición de complementariedad $\mu_j g_j(w) = 0$ a $\mu_j g_j(w) = -t$ con $t > 0$. Sustituyendo en la estacionariedad y usando que $g_j(w) < 0$ en el interior,

$$\nabla f(w) + \sum_j \mu_j \nabla g_j(w) = \nabla f(w) - t \sum_j \frac{\nabla g_j(w)}{g_j(w)} = \nabla \left(f(w) - t \sum_j \ln(-g_j(w)) \right),$$

de modo que las ecuaciones KKT relajadas equivalen a anular el gradiente de la **función barrera**

$$G_t(w) = U_1(w) - t \sum_j \ln(-g_j(w)).$$

Para cada t fijo, G_t se minimiza con **Newton sin restricción**: si $\nabla^2 G_t \succ 0$,

$$w_{k+1} = w_k - [\nabla^2 G_t(w_k)]^{-1} \nabla G_t(w_k),$$

con búsqueda lineal por retroceso que mantiene $g_j(w) < 0$ (el iterado nunca abandona el interior). Se comienza con $t \in (0, 1)$ y se reduce t en cada iteración: al hacer $t \rightarrow 0$ la barrera se desvanece y los iterados se acercan a la frontera, convergiendo al óptimo global de (1). Obtenemos así el *óptimo exacto*.

3.4. Estrategia 2: minimización de una función cóncava

Al invertir el signo ($s = -1$) se minimiza $U_{-1}(w) = -a^\top w - \lambda w^\top \Sigma w$, cuyo Hessiano es

$$\nabla^2 U_{-1}(w) = -2\lambda \Sigma \preceq 0,$$

es decir, se minimiza una función *cóncava* (equivalentemente, se maximiza una función convexa) sobre Ω . Este problema no es convexo y, en general, es NP-difícil. Sin embargo, su estructura ofrece una guía precisa: por el principio del máximo de Bauer, una función convexa alcanza su máximo sobre un conjunto convexo y compacto en un *punto extremo*; luego el óptimo de (1) con $s = -1$ se encuentra en un **vértice** de Ω . El Punto Interior no es aplicable aquí: el Hessiano de su subproblema, $-2t\lambda\Sigma + \sum_j g_j g_j^\top / s_j^2$, es en general indefinido, por lo que el paso de Newton no es una dirección de descenso fiable ni garantiza convergencia. Empleamos en su lugar **Descenso de Gradiente Proyectado**, un método de direcciones factibles de primer orden aplicado a U_{-1} :

$$w^{k+1} = \Pi_\Omega(w^k - \eta \nabla U_{-1}(w^k)) = \Pi_\Omega(w^k + \eta(a + 2\lambda\Sigma w^k)).$$

Como U_{-1} es cóncava, el descenso empuja los iterados hacia la frontera y, finalmente, a un vértice; con varios reinicios aleatorios factibles se mitiga la no convexidad y se conserva el mejor resultado. La proyección euclidiana $\Pi_\Omega(y)$ es el subproblema que el Punto Interior resuelve en cada paso:

$$\Pi_\Omega(y) = \arg \min_x \frac{1}{2} \|x - y\|^2 \quad \text{s.a.} \quad \mathbf{1}^\top x = p_k, \quad \ell_p \leq \sum_{i \in P_p} x_i \leq u_p, \quad \sum_{\text{adp}_i < P_m} x_i \leq m, \quad 0 \leq x_i \leq 1,$$

es decir, exactamente la región Ω de (1) (presupuesto, cupos por posición, factibilidad de ADP y caja) pero con objetivo $\frac{1}{2} \|x - y\|^2$, cuyo Hessiano es $I \succ 0$: un programa cuadrático *convexo* que se resuelve con el Punto Interior de la Sección 3.2. El problema no convexo se descompone así en subproblemas convexos. A diferencia de la Estrategia 1, aquí no hay certificado de optimalidad global: el método entrega un vértice de alta calidad, no necesariamente el óptimo.

3.5. De la relajación a una selección discreta

El vector w de (1) es una relajación continua: nombra la plantilla óptima restante reclutable, pero un *draft* es secuencial y en cada turno solo se elige un jugador. La estrategia de piso elige, entre los candidatos con valor positivo sobre el siguiente disponible ($a_i > 0$), el que maximiza la utilidad marginal $a_i - \lambda(\Sigma_{ii} + 2\Sigma_{i,R})$, donde $\Sigma_{ii} + 2\Sigma_{i,R}$ es el cambio exacto en la varianza del equipo al añadir al jugador i a la plantilla R ya poseída. El filtro $a_i > 0$ es esencial: un jugador de valor nulo (un *kicker* o defensa, que seguirá disponible muchas rondas) es aplazable sin costo, y sin el filtro el piso gastaría una selección temprana en él por ser un reductor de varianza barato; esos jugadores solo se toman cuando nada aporta valor (últimas rondas). La estrategia de techo no usa la regla marginal, pues premiar la varianza turno a turno gastaría selecciones tempranas en activos de varianza máxima y valor nulo; su preferencia por la varianza ya vive en la relajación que resuelve, así que basta extraer de la plantilla óptima al jugador de mayor valor a_i . Tras la selección, los rivales eligen y el problema (1) se resuelve de nuevo con el estado actualizado.

4. Simulaciones y resultados

Evaluamos el modelo en una liga PPR de 12 equipos y 16 cupos para la temporada 2025, mediante *drafts* de Monte Carlo en los que la posición de selección del participante varía aleatoriamente. Como punto de comparación se incluyen dos heurísticas habituales en *fantasy*, que no resuelven ninguna optimización: **ADP**, que en cada turno toma al jugador disponible con menor posición media de selección, y **VBD** (*value-based drafting*), que toma al jugador con mayor valor sobre el nivel de reemplazo de su posición. Cada estrategia se evalúa con la función objetivo que ella misma optimiza: Markowitz por $U_1 = \text{pts} - \lambda r$, Upside por $U_2 = \text{pts} + \lambda r$, y las heurísticas por puntos esperados, su único criterio.

Estrategia	Criterio propio	Valor propio	Puntos	Riesgo
Markowitz (piso)	$U_1 = \text{pts} - \lambda r$	2613,1	2898,2	285,1
Upside (techo)	$U_2 = \text{pts} + \lambda r$	3591,3	3013,6	577,7
VBD (heurística)	puntos	2938,5	2938,5	494,6
ADP (heurística)	puntos	2868,7	2868,7	548,7

Cuadro 1: Resultados de Monte Carlo. Cada fila reporta el valor del criterio que esa estrategia optimiza, junto con los puntos esperados y el riesgo del equipo resultante.

Como la factibilidad de ADP obliga a las cuatro estrategias a armar plantillas igualmente reclutables, la comparación ya no premia a quien acumula estrellas inalcanzables, sino que revela la actitud ante el riesgo de cada una. Markowitz obtiene el menor riesgo de equipo (285,1), cerca de la mitad del de las heurísticas, con puntos esperados a media tabla (2898,2): es la elección cuando se busca consistencia. Upside, en cambio, alcanza el mayor valor de techo ($U_2 = 3591,3$) y, de hecho, los puntos brutos más altos (3013,6), al precio de la varianza más alta (577,7): apuesta por la cola alta. Ninguna estrategia domina a la otra; cada una es la mejor bajo el criterio que persigue, que es precisamente lo que se busca al leer la misma covarianza con signo opuesto.

Las heurísticas quedan encajonadas: ADP (2868,7 puntos) y VBD (2938,5) logran un rendimiento medio comparable al de la estrategia de piso, pero a un riesgo fijo y casi el doble, porque no optimizan nada sobre la covarianza. El aporte de la optimización no es ganar en puntos a igualdad de plantillas reclutables, sino *elegir* dónde situarse en el plano riesgo y rendimiento.

La Figura 1 resume la separación: Markowitz en la región de menor riesgo, Upside en la de mayor techo y las heurísticas fijas en un riesgo intermedio. La Figura 2 ilustra una decisión




Figura 1: Izquierda: utilidad media ($\pm$ desviación estándar) de cada estrategia bajo su propia métrica. Derecha: puntos esperados frente a riesgo del equipo. Con la factibilidad de ADP, las cuatro estrategias arman plantillas igualmente reclutables, así que la comparación es justa. Markowitz produce el riesgo más bajo (estrategia de piso); Upside maximiza su métrica de techo; las heurísticas quedan en un riesgo intermedio y fijo.




Figura 2: Una decisión real en el plano (riesgo, rendimiento): Ronda 4 del puesto 1 de selección, con tres jugadores ya en la plantilla. Las curvas de nivel son la utilidad verdadera; Markowitz ($U = \text{ret} - \lambda \text{riesgo}^2$) prefiere la zona superior izquierda (más puntos, menos riesgo) y Upside ($U = \text{ret} + \lambda \text{riesgo}^2$) la superior derecha. La estrella marca la selección de cada estrategia: la de piso asegura al receptor estable de menor varianza (Courtland Sutton) y la de techo apuesta por el corredor de mayor varianza (Breece Hall).

concreta: en la Ronda 4 desde el puesto 1, la estrategia de piso asegura al receptor estable de menor varianza y la de techo apuesta por el corredor de mayor varianza, y las curvas de nivel muestran que ambas optimizan la misma cantidad con preferencias opuestas. La factibilidad de ADP ordena las selecciones de forma realista: los *running backs*, escasos, se eligen pronto y los *kickers* y defensas caen a las últimas rondas.

En conjunto, un único modelo de covarianza, leído con signo opuesto, produce dos filosofías de *draft* coherentes: una de piso, que es un programa cuadrático convexo con óptimo exacto vía Punto Interior, y una de techo, no convexa, abordada con Descenso de Gradiente Proyectado cuya proyección vuelve a ser un programa cuadrático convexo; la curvatura del problema determina el método aplicable. Sobre datos reales y una covarianza sensible a la disponibilidad, y evaluado en una temporada ajena a la estimación, el modelo convierte el *draft* en una optimización transparente y ajustable, y no en una simple heurística de ordenamiento.